

SAE 4.01 : Expliquer ou prédire une variable quantitative à partir de plusieurs facteurs

Est-il possible d'expliquer par un modèle de régression linéaire la durée du sommeil ?

Loris Bouet | Amélie Condette | François Manoury

GROUPE B

IUT Vannes – Année universitaire 2024/2025

BUT Science des Données – Semestre 4

LISTE DES SIGLES

AIC : Critère d'information d'Akaike

BIC : Critère d'information bayésien

BPM : Battements par minute

FCN : Fréquence cardiaque nocturne

IMC : Indice de masse corporelle

VIF : Variance inflation factor

SOMMAIRE

Introduction	5
1 Un jeu de données complet sur l'hygiène et le mode de vie	6
1.1 Nos données	6
1.2 Traitements des données	6
2 Méthodologie.....	8
3 Les statistiques descriptives de nos variables	10
3.1 Analyses univariées.....	10
3.1.1 La variable à expliquer	10
3.1.2 Les variables explicatives quantitatives.....	10
3.1.3 Les variables explicatives qualitatives	13
3.2 Les corrélations entre variables.....	15
3.2.1 Analyse des variables quantitatives.....	15
3.2.2 Durée de sommeil.....	15
3.2.3 Analyse des variables qualitatives	16
3.3 Analyses bivariées.....	19
3.3.1 La durée du sommeil en fonction de sa qualité	19
3.3.2 La durée du sommeil en fonction du métier	19
3.3.3 La durée du sommeil en fonction de la catégorie d'IMC.....	20
3.4 Test de Tukey	20
4 Modèle de régression	22
4.1 Construction du modèle	22
4.2 Entraînement et test du modèle	26
4.3 Explication du modèle.....	27
Conclusion.....	29
Lexique	30

INTRODUCTION

Le sommeil est un état modifié de la conscience du monde extérieur (sans perte de la réception sensitive), accompagné d'une diminution progressive du tonus musculaire¹, survenant à intervalles réguliers. Chez l'être humain, le sommeil représente plus d'un tiers de notre vie et est déterminant pour la croissance, la maturation cérébrale, le développement et la préservation de nos capacités cognitives. Il est essentiel pour l'ajustement de nombreuses sécrétions hormonales et pour le maintien de notre température interne. On sait aujourd'hui que la réduction du temps de sommeil ou l'altération de sa qualité impactent la santé physique ou mentale. Enfin, la mise au repos de notre système cardiovasculaire au cours du sommeil est l'un des enjeux de prévention des années à venir. Pour toutes ces raisons, être en mesure d'expliquer comment obtenir un sommeil de qualité, suffisamment long, peut être bénéfique pour la santé publique.

Le jeu de données qui nous a servi d'étude contient suffisamment de variables et de facteurs (provenant des domaines physiques, environnementaux et comportementaux) pour pouvoir espérer expliquer la durée du sommeil. Dans le cadre de notre projet et des acquis statistiques qui sont les nôtres, nous avons choisi d'explorer la problématique suivante : pouvons-nous expliquer la durée du sommeil par un modèle de régression linéaire ?

Il conviendra de commencer par expliquer plus en détails notre jeu de données, et les traitements qui ont dû être réalisés. Nous verrons ensuite quelle est la méthodologie que nous avons mise en place pour construire des modèles statistiquement valides, basés sur les variables que nous analyserons de manière uni et bivariées, dans une troisième partie. Enfin, il conviendra de développer comment et pourquoi nous avons abouti à un modèle en particulier et quelle conclusion nous pouvons en tirer.

¹ **Tonus musculaire** : C'est la contraction légère et constante des muscles au repos, permettant de maintenir la posture et la stabilité du corps. Voir lexique p.30

UN JEU DE DONNEES COMPLET SUR L'HYGIENE ET LE MODE DE VIE

1.1 Nos données

Le jeu de données comprend 373 observations et 12 variables, permettant d'étudier les relations entre les habitudes de sommeil, la santé et le mode de vie. Toutes ces variables sont intéressantes et nécessaires pour comprendre les différents facteurs qui influencent la durée du sommeil, exprimée en heure.

Plusieurs variables explicatives quantitatives et qualitatives permettent d'analyser cette durée. Parmi les variables quantitatives, nous avons l'âge, le niveau d'activité physique donné en minutes par jour, le niveau de stress mesuré par une note de 1 à 10. Mais aussi, la pression artérielle avec la pression systolique² et la pression diastolique³, la fréquence cardiaque en battements par minute (BPM) et le nombre de pas quotidiens sont intégrés à l'analyse.

En parallèle, nous avons des variables catégorielles comme le genre de la personne (2 modalités), son métier (11 modalités), l'Indice de Masse Corporelle de l'individu (IMC) (3 modalités) et le type de trouble du sommeil (3 modalités).

Toutes ces variables, quantitatives et catégorielles, peuvent jouer un rôle plus ou moins important pour la prédiction de la durée du sommeil.

1.2 Traitements des données

Pour réaliser ce projet, nous avons suivi plusieurs étapes méthodologiques essentielles afin de répondre de manière précise et rigoureuse à notre problématique. Ces étapes ont permis de structurer notre approche, de garantir la qualité de nos analyses, et de fournir des résultats pertinents et fiables.

Tout d'abord, nous avons commencé par préparer les données qui nous ont été fournies. Cette étape de préparation a été nécessaire pour s'assurer que les données étaient cohérentes et prêtes à être exploitées dans nos analyses. Nous avons recordé certaines

² **Pression artérielle systolique** : il s'agit de la pression exercée par le sang sur les parois des artères lors de la contraction du cœur (systole). Voir lexique p.30

³ **Pression artérielle diastolique** : il s'agit de la pression exercée par le sang sur les parois des artères lorsque le cœur est au repos entre deux battements (diastole). Voir lexique p.30

variables afin de simplifier leur interprétation. Par exemple, dans la variable concernant l'IMC, nous avons les modalités « *Normal weight* » et « *Normal* », qui se référaient en réalité à la même catégorie. Nous avons donc regroupé ces deux modalités sous une seule étiquette « *Corpulence normale* » pour éviter toute ambiguïté. De plus, toutes les données qualitatives étaient initialement présentées en anglais ; nous avons pris l'initiative de les traduire en français pour rendre les résultats et les interprétations plus accessibles à nos interlocuteurs. Par exemple, la modalité « *Overweight* » a été traduite par « *Surpoids* », facilitant ainsi la compréhension des résultats par un public francophone.

Pour compléter cette phase de préparation, nous avons également traité la variable de la pression artérielle. Initialement, la pression systolique et la pression diastolique étaient combinées dans une seule variable sous la forme « *systolique/diastolique* ». La pression artérielle étant une donnée quantitative, nous avons séparé cette variable en deux variables distinctes : une pour la pression systolique et l'autre pour la pression diastolique. Cela nous a permis d'explorer plus précisément l'impact de la pression artérielle sur la durée du sommeil.

Ces étapes de recodage, de traduction et de séparation des variables ont constitué la base nécessaire pour procéder à l'analyse concrète, en garantissant que les données étaient bien structurées et adaptées à nos objectifs de recherche.

METHODOLOGIE

Tout d'abord, nous avons réalisé diverses analyses statistiques, en débutant par des études descriptives afin d'avoir une meilleure vision de nos différentes variables.

Pour commencer, nous avons décidé de réaliser deux tests de Tukey à la suite de nos analyses descriptives, afin de voir si certains métiers ou certaines catégories d'IMC avaient une durée de sommeil moyenne significativement différente. Ce test nous a permis d'avoir une première vision avant la construction de notre modèle définitif.

Par ailleurs, nous avons analysé la corrélation entre les variables ainsi que le Variance Inflation Factor (VIF) pour détecter et gérer la colinéarité dans nos modèles de régression sur les variables quantitatives et le V de Cramer pour les variables catégorielles. En effet, ces vérifications sont cruciales pour éviter les problèmes de corrélation dans notre modèle, une hypothèse fondamentale à la construction. En outre, ces analyses contribuent à pouvoir construire notre modèle et à faciliter la compréhension de l'impact de chaque variable explicative sur la durée du sommeil.

D'autre part, afin de construire nos modèles linéaires, nous avons décidé d'utiliser la méthode "pas à pas" pour identifier les variables qui influencent significativement la durée du sommeil et qui améliorent la qualité d'ajustement de notre modèle.

Il existe différentes variantes de cette méthode. L'approche descendante, où nous partons du modèle avec toutes les variables et éliminons successivement des variables en se basant sur un critère de choix. L'approche ascendante où, à l'inverse, nous partons du modèle vide, avec seulement la constante, et nous rajoutons à chaque étape une variable en se basant sur un critère de choix. Enfin l'approche ascendante-descendante, qui est une combinaison des deux approches précédentes, en partant du modèle vide. A chaque étape, nous rajoutons donc une variable, puis, nous regardons si une variable du modèle ne doit pas être retirée. Pour nos modèles nous avons utilisé la méthode ascendante-descendante.

Pour chaque méthode, nous avons un critère de performance qui est, soit basé sur un test d'hypothèse, par exemple : test de nullité de *Student*, soit sur un indicateur de qualité

comme le critère d'information d'Akaike (AIC), le critère d'information bayésien⁴ (BIC), ou encore le R^2 ajusté. Pour notre analyse nous avons choisi de comparer nos modèles à l'aide du R^2 ajusté et du BIC.

Dans un premier temps, le R^2 ajusté permet de comparer différents modèles ayant des tailles différentes, car il tient compte du nombre de variables incluses dans chaque modèle. Contrairement au R^2 classique, qui augmente avec l'ajout de nouvelles variables, le R^2 ajusté pénalise les modèles trop complexes, offrant ainsi une mesure plus fiable de la qualité du modèle en fonction de son nombre de paramètres.

Dans un second temps, le BIC est un indice statistique utilisé en statistique bayésienne pour comparer et choisir entre plusieurs modèles alternatifs. La sélection de modèles consiste à choisir le modèle statistique le plus approprié parmi un ensemble de modèles candidats, en se basant sur les données disponibles. Dans ce processus, on cherche à minimiser le BIC. En effet, il optimise le nombre de paramètres du modèle tout en cherchant à ajuster au mieux les données. Ainsi, un modèle avec un BIC plus faible est meilleur, car cela indique qu'il explique bien les données tout en étant suffisamment simple pour éviter le surplus de variables et un surajustement.

Pour finir, une fois nos modèles sélectionnés avec la dernière méthode, nous les avons entraînés et testés afin de s'assurer une bonne précision de prédiction. Nous avons également utilisé la méthode Bootstrap afin de calculer l'écart quadratique moyen (RMSE) sur des échantillons aléatoires de nos données, et savoir la précision moyenne que nous obtenons sur ces derniers.

⁴ **Bayésien** : Méthodes d'inférence statistique fondées sur une évaluation des probabilités des hypothèses, préalablement à l'observation d'un événement aléatoire. Voir lexique p.30

LES STATISTIQUES DESCRIPTIVES DE NOS VARIABLES

1.3 Analyses univariées

Dans une démarche de travail préparatoire en vue de former nos futurs modèles, nous avons pris le temps d'effectuer l'analyse univariée de chacune des variables à notre disposition. Celles-ci nous permettent de mieux comprendre nos données et ses éventuelles particularités.

1.3.1 La variable à expliquer

La variable que nos modèles doivent expliquer est la durée du sommeil, quantifiée en heures. Au sein de notre jeu de données, cette durée de sommeil s'étend entre 5,8 heures et 8,5 heures, avec une médiane à 7,2 heures. Globalement, les individus sont répartis de manière assez homogène au sein de cette étendue.




Figure 1 - Répartition de la durée du sommeil

Min	Q1	Médiane	Moyenne	Q3	Max
5,8	6,4	7,2	7,129	7,8	8,5

Tableau 1 - Statistiques descriptives de la durée de sommeil

1.3.2 Les variables explicatives quantitatives

Nous avons 6 variables explicatives quantitatives au sein de notre jeu de données. Il s'agit de la fréquence cardiaque nocturne ; de l'âge ; du niveau d'activité physique ; du nombre de pas quotidien ; de la pression artérielle systolique et de la pression artérielle

diastolique. Voici les analyses descriptives univariées des 3 variables les plus pertinentes dans notre étude.

La fréquence cardiaque nocturne (FCN) des individus est une variable pouvant avoir un lien direct avec la qualité de sommeil. En effet, si chacun a son propre rythme, une fréquence élevée a tout de même tendance à être associée avec un sommeil peu réparateur. Dans le cas de notre population, la majorité se situe dans une FCN relativement basse, tandis que seul le dernier quartile contient des données qui commencent à être élevée, dépassant les 75-80 bpm.




Figure 2 – Distribution de la fréquence cardiaque des individus

Min	Q1	Médiane	Moyenne	Q3	Max
65	68	70	70,17	72	86

Tableau 2 2 – Statistiques descriptives de la fréquence cardiaque des individus.

L'étude de l'âge de la population nous permet de constater qu'elle est constituée d'individus majoritairement jeunes. Ainsi, seulement 25 % de l'effectif à plus de 50 ans, tandis que la moyenne est de 42 ans. Cela peut s'expliquer par le fait que le jeu de données semble constituer autour d'une population d'actifs, comme en témoigne la variable métier, qui sera abordée plus tard dans ce rapport.




Figure 32 – Répartition de l'âge des individus

Min	Q1	Médiane	Moyenne	Q3	Max
27	35	43	42,14	50	50,59

Tableau 3 3 – Statistiques descriptives de l'âge des individus.

Pour conclure sur les variables quantitatives, le niveau d'activité physique a été quantifié par un score, allant de 30 à 90. Si la signification de celui-ci n'est pas totalement claire, dans la mesure où il n'est pas traduisible par ce qui pourrait être un nombre d'heures d'entraînement, par exemple, il permet tout de même de quantifier ce facteur. La variable a d'ailleurs probablement été centrée, ce qui rend une distribuée de manière homogène. Le minimum est ainsi à 30, la médiane à 60 et le maximum à 90.




Figure 4 3 – Répartition du niveau d'activité physique

Min	Q1	Médiane	Moyenne	Q3	Max
30	45	60	59,13	75	90

Tableau 4 4 – Statistiques descriptives du niveau d'activités des individus.

1.3.3 Les variables explicatives qualitatives

Notre jeu de données contient 5 variables qualitatives : le genre ; les troubles du sommeil ; le niveau de stress ; les métiers et la catégorie d'IMC. De la même manière que pour les variables quantitatives, seules les 3 variables les plus pertinentes vont être développées ci-dessous.

Les troubles du sommeil sont répertoriés en 3 modalités : aucun ; apnée du sommeil ; insomnie. Nous voyons dans la figure 6 que 59 % des individus ne présentent aucun trouble, tandis que les deux autres modalités concernent exactement la même proportion de personnes, à savoir chacune environ 20,5 % de l'effectif.




Figure 4 4 – Répartition des troubles du sommeil au sein de la population étudiée

Le niveau de stress des individus étudiés est réparti plutôt équitablement. Cette variable est matérialisée par un barème allant de 3 à 8, du moins au plus stressé que nous avons recodé de la manière suivante : peu stressé ; moyennement stressé ; très stressé. La répartition au sein de la population est plutôt homogène, puisque les modalités représentent respectivement : 38 % ; 30 % ; 32 % de l'effectif total.




Figure 5 5 – Répartition des niveaux de stress au sein de la population étudiée

La catégorie d'IMC est la dernière variable qui sera développée. S'il est sujet à quelques critiques, cet indicateur met tout de même en avant de potentiel déséquilibre dans la constitution physique d'un individu. Trois modalités sont ici représentées : Corpulence normale ; Surpoids ; Obèse. Pour ces deux dernières, nous savons que cela est généralement corrélé avec un état de santé dégradé, pouvant potentiellement nuire à la qualité du sommeil, cette variable est donc particulièrement intéressante à insérer dans notre étude. Au sein de notre population, la répartition est la suivante : 58 % des individus ont une corpulence normale ; 39 % sont en surpoids ; 3 % sont obèses.




Figure 66 – Répartition des catégories d'IMC au sein de la population étudiée

1.4 Les corrélations entre variables

Afin d'analyser la corrélation entre les différentes variables étudiées dans le cadre de notre rapport sur le sommeil, nous avons opté pour l'utilisation de deux méthodes statistiques complémentaires. Ces méthodes permettent d'identifier les relations entre les variables, qu'elles soient quantitatives ou qualitatives, et d'évaluer l'intensité et la direction de ces relations.

1.4.1 Analyse des variables quantitatives

Dans un premier temps, pour les variables quantitatives, nous avons choisi d'utiliser la matrice des corrélations suivante :




Figure 77 – Matrice des corrélations des variables quantitatives

D'autre part, étant donné que nous avons réalisé un indice de VIF afin de vérifier quelles sont les variables ayant une forte corrélation avec les autres pour la durée du sommeil.

1.4.2 Durée de sommeil

Âge	Activité physique	Fréquence cardiaque	Pas quotidien	Pression systolique	Pression diastolique
2,25	2,98	1,64	3,04	30,47	30,89

Tableau 55 - VIF de nos variables quantitatives

En étudiant la matrice des corrélations et le VIF ci-dessus, nous pouvons voir que certaines variables explicatives ne peuvent pas non plus apparaître simultanément dans notre modèle expliquant la durée de sommeil.

En analysant le corrélogramme et les indices VIF, il apparaît que certaines variables explicatives ne peuvent pas être intégrées simultanément dans notre modèle de prédiction de la durée du sommeil en raison de leur forte corrélation. Par exemple, les pressions artérielles systolique et diastolique étant étroitement liées avec une corrélation de 0,97 et affichant un VIF élevé avec respectivement 30,47 et 30,89. Leur présence conjointe pourrait entraîner des problèmes de redondance. Comme elles sont toutes deux corrélées de manière similaire avec la durée du sommeil, nous choisissons de conserver uniquement la pression artérielle systolique. Elle présente une corrélation moins élevée avec les autres variables explicatives et une corrélation plus élevée avec la variable à expliquer. D'autre part, nous avons choisi de supprimer la variable nombre de pas car elle avait une corrélation de 0,77 avec l'activité physique. Une corrélation, peu étonnante car plus nous faisons une activité physique plus nous faisons de pas.

Si nous résumons cette partie, nous enlèverons le nombre de pas journalier et la pression artérielle diastolique de notre modèle de données expliquant la durée du sommeil afin d'éviter les problèmes de colinéarités entre nos variables explicatives.

1.4.3 Analyse des variables qualitatives

Dans un premier temps, pour les variables qualitatives, nous avons décidé d'analyser le V de Cramer. Cet indicateur permet de mesurer l'intensité de l'association entre 2 variables catégorielles :

V²Cramer	IMC	Métier	Genre	Trouble du sommeil	Qualité du sommeil	Niveau de stress
IMC	NA	0,55	0,40	0,57	0,39	0,42
Métier	0,55	NA	0,84	0,74	0,62	0,66
Genre	0,57	0,84	NA	0,38	0,17	0,68

Trouble du sommeil	0,39	0,74	0,38	NA	0,33	0,33
Qualité du sommeil	0,39	0,62	0,17	0,33	NA	0,50
Niveau de stress	0,42	0,66	0,68	0,33	0,50	NA

Tableau 6 6 – V²Cramer de nos variables explicatives quantitatives

Le calcul du V de Cramer met en évidence une forte association entre le métier d'une personne et son genre ainsi que ses troubles du sommeil. Une valeur de 0.84 entre le métier et le genre indique que certaines professions sont occupées majoritairement par un genre spécifique, ce qui peut être lié à des facteurs socioculturels ou à des choix professionnels. De même, la corrélation de 0.74 entre le métier et les troubles du sommeil montre que certaines professions peuvent exposer davantage à des rythmes de travail perturbés, au stress ou à des conditions engendrant des troubles du sommeil.

Face à ces résultats, nous avons choisi d'approfondir l'analyse en examinant les liens spécifiques entre chaque métier et le genre des individus, ainsi que les associations entre chaque métier et les troubles du sommeil. Cette exploration nous permettra de mieux comprendre les inégalités potentielles en matière de conditions de travail et leurs impacts sur la santé. Pour cela, nous avons réalisé la matrice des corrélations de ces variables catégorielles :




Figure 88 – Matrice des corrélations des variables qualitatives

Cette matrice des corrélations met en évidence que la plupart des métiers ne présentent pas de corrélation significative avec le genre ou les troubles du sommeil. Toutefois, une exception est observée chez les infirmiers, où une association significative avec les apnées du sommeil est visible.

Dans ce contexte, l'absence de corrélations fortes pour la majorité des professions signifie qu'aucune variable ne semble redondante ou inutile. Ainsi, nous avons décidé de conserver toutes les variables dans nos modèles afin de ne pas risquer de perdre des informations pertinentes qui pourraient influencer les résultats de l'analyse.

1.5 Analyses bivariées

Afin de continuer à améliorer notre compréhension du jeu de données, nous avons aussi mis en place des analyses bivariées, axées sur notre variable à expliquer : la durée de sommeil. Dans le cas des exemples affichés, nous verrons que certaines tendances semblent se dégager.

1.5.1 La durée du sommeil en fonction de sa qualité




Figure 9 9 – Durée du sommeil en fonction de sa qualité

Ces boîtes à moustache semblent illustrer de fortes disparités dans la durée de sommeil, selon la qualité de celui-ci. Ainsi, l'étendue de la durée de sommeil des individus ayant un sommeil de mauvaise qualité est bien plus basse : de 5,8 à 6,6 heures, là où les individus ayant un sommeil de bonne qualité semblent dormir bien plus longtemps : 7,3h au minimum, pour 8,5h au maximum.

1.5.2 La durée du sommeil en fonction du métier




Figure 10 10 – Durée du sommeil en fonction du métier

Le croisement de la variable métier avec la durée du sommeil apporte des tendances : nous remarquons par exemple que les ingénieurs semblent dormir en moyenne plus

longtemps que les autres professions, tout comme les avocats, à l'inverse des vendeurs et des professeurs qui semblent dormir peu.

1.5.3 La durée du sommeil en fonction de la catégorie d'IMC




Figure 1111 – Durée du sommeil en fonction de la catégorie d'IMC

Pour conclure sur ces exemples d'analyses bivariées, la durée du sommeil en fonction de l'IMC tend à fournir quelques informations. Ainsi, il semblerait que les individus à corpulence normale dorment généralement plus longtemps. Cette donnée paraît beaucoup plus aléatoire pour les personnes obèses, tandis que les personnes en surpoids semblent dormir globalement moins.

La pertinence de toutes ces tendances vues dans les analyses bivariées peut être statistiquement évaluée par un test statistique, celui de Tukey.

1.6 Test de Tukey

Avant de rentrer dans les détails des tests effectués, rappelons le but d'un test de Tukey. Ce test part d'un modèle avec une variable y expliquée par une variable qualitative. Il regarde, pour chaque paire de modalité de cette variable explicative, s'il y a une différence significative de valeur de la variable à expliquer. Dans ce cadre, notre hypothèse nulle pour chaque paire de modalité, est que la moyenne sur la population est la même. Tandis que notre hypothèse alternative est que ces moyennes sont différentes. Rappelons également que pour conclure la significativité du test, il faut que la p -valeur soit inférieure à 5% et que la valeur observée T_{obs} soit supérieure au quantile $t_{1-\frac{\alpha}{2}}^{n-(p+1)}$.

Nous avons commencé par effectuer ce test pour les métiers. Les résultats de ce test qui ressortent le plus sont que les ingénieurs et les avocats dorment en moyenne plus que les autres professions avec les ingénieurs qui dorment également plus que les avocats.

Ensuite nous l'avons également fait pour les catégories d'IMC. Cette fois-ci, le test nous montre un sommeil en moyenne plus long chez les personnes de corpulence normale que chez les personnes en surpoids.

MODELE DE REGRESSION

1.7 Construction du modèle

Comme énoncé dans la partie méthodologie, afin de construire nos modèles linéaires, nous avons décidé d'utiliser la méthode "pas à pas ascendante-descendante". La formule R de cette méthode nous sert plusieurs modèles par critère de qualité d'ajustement. Plus précisément, si on prend l'exemple du R^2 ajusté, elle va nous montrer le meilleur modèle par nombre de paramètres et nous afficher la valeur du R^2 ajusté pour ce dernier. Dans notre cas, nous avons décidé de nous concentrer sur les modèles retenus pour les critères du BIC et du R^2 ajusté.

Afin de nous aider à mieux voir les modèles qui optimisaient les deux critères, nous avons affiché plusieurs graphiques :




Figure 1213 - Nombre de paramètres optimisant le BIC




Figure 1312 - Graphique de sélection à partir du modèle BIC

Nous avons regardé les mêmes graphiques pour le R^2 ajusté (cf. Annexe 1). La première sortie nous permet de connaître le nombre de paramètres du modèle qui optimise le critère. Pour le BIC, nous pouvons voir que le modèle optimal comporte 12 paramètres tandis que pour le R^2 ajusté, il en comporte 17. La deuxième sortie affiche les paramètres de chaque modèle en face de la valeur du critère associé. Afin d'avoir une meilleure vision de celui qui optimise le critère, nous avons directement affiché les noms.

Finalement, les deux modèles retenus sont les suivants :

$y_i = \beta_0 + \beta_{\text{doct}}x_{i \text{ doct}} + \beta_{\text{inge}}x_{i \text{ inge}} + \beta_{\text{avoc}}x_{i \text{ avoc}} + \beta_{\text{autre}}x_{i \text{ autre}} + \beta_{\text{infirm}}x_{i \text{ infirm}} + \beta_{\text{vend}}x_{i \text{ vend}} + \beta_{\text{prof}}x_{i \text{ prof}} + \beta_{\text{mauvaise}}x_{i \text{ mauvaise}} + \beta_{\text{bonne}}x_{i \text{ bonne}} + \beta_{\text{peu}}x_{i \text{ peu}} + \beta_{\text{tres}}x_{i \text{ tres}} + \beta_{\text{press}}\text{press}_i + \beta_{\text{age}}\text{age}_i + \beta_{\text{obese}}x_{i \text{ obese}} + \beta_{\text{surpoids}}x_{i \text{ surpoids}} + e_i$
$y_i = \beta_0 + \beta_{\text{doct}}x_{i \text{ doct}} + \beta_{\text{inge}}x_{i \text{ inge}} + \beta_{\text{avoc}}x_{i \text{ avoc}} + \beta_{\text{autre}}x_{i \text{ autre}} + \beta_{\text{infirm}}x_{i \text{ infirm}} + \beta_{\text{vend}}x_{i \text{ vend}} + \beta_{\text{prof}}x_{i \text{ prof}} + \beta_{\text{mauvaise}}x_{i \text{ mauvaise}} + \beta_{\text{bonne}}x_{i \text{ bonne}} + \beta_{\text{peu}}x_{i \text{ peu}} + \beta_{\text{tres}}x_{i \text{ tres}} + \beta_{\text{press}}\text{press}_i + \beta_{\text{age}}\text{age}_i + \beta_{\text{obese}}x_{i \text{ obese}} + \beta_{\text{surpoids}}x_{i \text{ surpoids}} + \beta_{\text{insomnie}}x_{i \text{ insomnie}} + \beta_{\text{apnée}}x_{i \text{ apnée}} + \beta_{\text{homme}}x_{i \text{ homme}} + \beta_{\text{niv_act}}\text{niv_act}_i + \beta_{\text{freq_card}}\text{freq_card}_i + e_i$

Nous avons décidé de garder les 2 modèles afin de pouvoir les comparer. Nous retrouvons dans le premier modèle ces différents indicateurs :

BIC	R^2 ajusté	RMSE
95,137	0,905	0,240

Tableau 7 7 - Indicateurs du modèle 1

Et dans le deuxième modèle, les indicateurs suivants :

BIC	R^2 ajusté	RMSE
112,935	0,906	0,236

Tableau 8 8 - Indicateurs du modèle 2

Avec ces deux résultats nous voyons que les deux modèles sont assez similaires au niveau des indicateurs. Cependant, le BIC est plus faible sur le premier modèle, cette information pourrait nous pousser à prendre le modèle 1.

Avant de passer à la suite de nos analyses, nous avons vérifié la validité des modèles. En effet, plusieurs hypothèses sont posées sur les erreurs d'un modèle et si elles ne sont pas

vérifiées, le modèle ne peut pas être utilisé, il n'est pas valide. Pour rappel, les hypothèses sont les suivantes :

- Les erreurs sont centrées
- Les erreurs sont de même variance
- Les erreurs sont non corrélées entre elles
- Les erreurs suivent une loi normale

Afin de vérifier ces dernières nous avons utilisé les graphiques suivants :




Figure 1415 - Histogramme présentant le centrage des résidus




Figure 14 - Graphiques des hypothèses des résidus

Nous avons fait les mêmes graphiques pour les 2 modèles mais ne présentons que ceux du modèle optimisant le BIC puisqu'ils se ressemblent.

Sur le premier graphique, nous pouvons voir que les résidus du modèle sont centrés car ils sont répartis également autour de 0.

Le second graphique ne vérifie pas d'hypothèse mais il vérifie la qualité d'ajustement du modèle. Nous pouvons voir qu'elle est plutôt bonne puisque les deux courbes des valeurs observées et ajustées se superposent.

Le troisième graphique, en haut à gauche, permet de vérifier l'homoscédasticité des résidus. Nous pouvons voir que la dispersion des résidus n'augmente pas lorsque les valeurs prédites augmentent. Donc l'hypothèse d'homoscédasticité est bien vérifiée. Et enfin, les résidus forment une droite sur le dernier graphique ce qui nous confirme également l'hypothèse que les résidus suivent une loi gaussienne.

1.8 Entraînement et test du modèle

Pour finir, une fois nos modèles sélectionnés avec la dernière méthode, nous les avons entraînés et testés afin de s'assurer une bonne précision de prédiction.

Pour cela, nous avons créé 200 échantillons aléatoires et avons calculé leur RMSE à l'aide de la méthode Bootstrap. A la fin, nous obtenons un RMSE moyen et des quantiles de valeurs suivantes :

RMSE moyen	0,2398	
Quantiles	2,5 %	97,5%
	0,1980	0,2824

Tableau 9 - RMSE pour le modèle optimisant le BIC

RMSE moyen	0,2359	
Quantiles	2,5 %	97,5%
	0,1968	0,2760

Tableau 10 - RMSE pour le modèle optimisant le R^2 ajusté

Ces deux tableaux nous montrent qu'en moyenne la précision des prédictions des deux modèles sur 200 échantillons est la même. De plus, le RMSE du quantile à 97,5% des deux échantillonnages est inférieur à l'écart type de notre variable y (0,7951). C'est un bon signe et nous montre que la précision de nos prédictions est bonne.

Dans ce contexte, nous avons finalement garder le sous-modèle afin d'optimiser le nombre de variables explicatives. Si nous interprétons le tableau précédent, notre modèle a une précision de prédiction de la durée de sommeil d'environ 15 minutes.

1.9 Explication du modèle

$$\hat{y}_i = 9,41 + 0,89x_{i \text{ doct}} + 0,60x_{i \text{ inge}} + 0,32x_{i \text{ avoc}} - 0,14x_{i \text{ autre}} + 0,47x_{i \text{ infirm}} + 0,67x_{i \text{ vend}} + 0,09x_{i \text{ prof}} + 0,97x_{i \text{ mauvaise}} + 0,40x_{i \text{ bonne}} - 0,25x_{i \text{ peu}} - 1,25x_{i \text{ tres}} - 0,72\text{press}_i + 0,51\text{age}_i + 0,45x_{i \text{ obese}} + 0,07x_{i \text{ surpoids}}$$

Maintenant que le modèle a été sélectionné, nous pouvons expliciter ses résultats. Selon celui-ci, la durée du sommeil s'explique selon les paramètres suivants :

- $\hat{\beta}_0 = 9,41$: si un individu correspond à toutes les modalités de référence, à savoir qu'il est comptable, de corpulence normale, moyennement stressé, qu'il a un sommeil de qualité moyenne, et que toutes les variables quantitatives sont nulles, sa durée de sommeil sera de 9h41. Soit une durée bien plus longue que le reste de la population étudiée, puisque certains coefficients négatifs n'ont pas été appliqués ;
- $\hat{\beta}_{\text{docteur}} = 0,89$: si l'individu est docteur, sa durée de sommeil augmentera de 0,89 heure ;
- $\hat{\beta}_{\text{ingénieur}} = 0,60$: si l'individu est ingénieur, sa durée de sommeil augmentera de 0,60 heure ;
- $\hat{\beta}_{\text{avocat}} = 0,32$: si l'individu est avocat, sa durée de sommeil augmentera de 0,32 heure ;
- $\hat{\beta}_{\text{autre}} = -0,14$: si l'individu a un des métiers de la modalité « autre »⁵, sa durée de sommeil diminuera de 0,14 heure ;
- $\hat{\beta}_{\text{infirmier}} = 0,47$: si l'individu est infirmier, sa durée de sommeil augmentera de 0,47 heure ;
- $\hat{\beta}_{\text{vendeur}} = 0,67$: si l'individu est vendeur, sa durée de sommeil augmentera de 0,67 heure ;

⁵ Software engineer ; manager ; scientifique ; représentant des ventes.

- $\hat{\beta}_{professeur} = 0,09$: si l'individu est professeur, sa durée de sommeil augmentera de 0,09 heure ;
- $\hat{\beta}_{mauvaise} = -0,97$: si l'individu a un sommeil de mauvaise qualité, sa durée de sommeil augmentera de 0,97 heure ;
- $\hat{\beta}_{bonne} = 0,40$: si l'individu a un sommeil de bonne qualité, sa durée de sommeil augmentera de 0,40 heure ;
- $\hat{\beta}_{peu\ stressé} = -0,25$: si l'individu est peu stressé, sa durée de sommeil diminuera de 0,25 heure ;
- $\hat{\beta}_{très\ stressé} = -1,25$: si l'individu est très stressé, sa durée de sommeil diminuera de 1,25 heure ;
- $\hat{\beta}_{pression\ systolique} = -0,72$: pour une unité de pression artérielle systolique divisée par 20, la durée de sommeil de l'individu diminuera de 0,72 heures ;
- $\hat{\beta}_{âge} = 0,51$: pour une unité d'âge divisée par 10, la durée de sommeil de l'individu augmentera de 0,51 heures ;
- $\hat{\beta}_{obèse} = 0,45$: si l'individu est obèse, sa durée de sommeil augmentera de 0,45 heure ;
- $\hat{\beta}_{surpoids} = 0,07$: si l'individu est en surpoids, sa durée de sommeil augmentera de 0,07 heure.

Concrètement, tous ces coefficients permettent de fournir des prédictions de cas particulier. Par exemple, un vendeur de 27 ans en surpoids, peu stressé, avec une pression artérielle systolique de 115 et un sommeil de bonne qualité, dormira entre 6,97 et 8,03 heures. A l'inverse, un comptable de 59 ans en surpoids, très stressé, avec une pression artérielle de 142 et un sommeil de qualité moyenne, ne dormira qu'entre 5,57 et 6,60 heures.

CONCLUSION

En conclusion, ce rapport a permis d'apporter des éléments de réponse à notre problématique, qui visait à expliquer la durée du sommeil par un modèle de régression. En analysant différents facteurs influençant la durée du sommeil, nous avons identifié les variables les plus significatives et évalué leur impact au travers d'un modèle statistique adapté. Nous avons gardé 12 paramètres présents dans 6 variables, qui sont l'âge, le métier, l'IMC, le niveau de stress, la pression artérielle systolique et la qualité du sommeil.

Les résultats obtenus montrent que notre modèle de régression est globalement pertinent pour expliquer les variations de la durée du sommeil, bien que certaines limites subsistent. L'analyse des coefficients et des performances du modèle nous a permis de mieux comprendre les relations entre les différents facteurs et la durée du sommeil. Toutefois, des améliorations pourraient être apportées en enrichissant l'ensemble de données ou en testant d'autres modélisations plus complexes.

Pour aller plus loin, nous pourrions ajouter de nouvelles variables tels que l'alimentation, la prise de médicament, les horaires de sommeil. En effet chacun de ses facteurs pourraient avoir un impact plus ou moins important. Par exemple, dans le cas où un individu consommerait de la caféine avant de dormir, l'explication pourrait être nuancée.

LEXIQUE

Bayésien : Méthodes d'inférence statistique fondées sur une évaluation des probabilités des hypothèses, préalablement à l'observation d'un événement aléatoire.

Diastolique : La pression artérielle diastolique est la pression exercée par le sang sur les parois des artères lorsque le cœur est au repos entre deux battements (diastole). Elle correspond à la valeur la plus basse de la pression artérielle et est mesurée en millimètres de mercure (mmHg).

Systolique : La pression artérielle systolique est la pression exercée par le sang sur les parois des artères lors de la contraction du cœur (systole). Elle correspond à la valeur la plus élevée de la pression artérielle et est mesurée en millimètres de mercure (mmHg).

Tonus musculaire : C'est la contraction légère et constante des muscles au repos, permettant de maintenir la posture et la stabilité du corps.

TABLE des matières

Liste des sigles	3
Sommaire	4
Introduction	5
1 Un jeu de données complet sur l'hygiène et le mode de vie	6
1.1 Nos données	6
1.2 Traitements des données	6
2 Méthodologie.....	8
3 Les statistiques descriptives de nos variables	10
3.1 Analyses univariées.....	10
3.1.1 La variable à expliquer	10
3.1.2 Les variables explicatives quantitatives.....	10
3.1.3 Les variables explicatives qualitatives	13
3.2 Les corrélations entre variables.....	15
3.2.1 Analyse des variables quantitatives.....	15
3.2.2 Durée de sommeil.....	15
3.2.3 Analyse des variables qualitatives	16
3.3 Analyses bivariées.....	19
3.3.1 La durée du sommeil en fonction de sa qualité	19
3.3.2 La durée du sommeil en fonction du métier	19
3.3.3 La durée du sommeil en fonction de la catégorie d'IMC.....	20
3.4 Test de Tukey	20
4 Modèle de régression	22
4.1 Construction du modèle	22
4.2 Entraînement et test du modèle	26
4.3 Explication du modèle.....	27

Conclusion	29
Lexique	30
Table des matières	31

ANNEXES

Annexe 1 : Sorties du modèle optimisant le R^2 ajusté

