

SAÉ 5-01 : Mener une étude statistique dans un domaine d'application

Domaine de l'agro-alimentaire

Réalisé par Titouan Béridel et Loris Bouet

23/01/2025

BUT Science des données

IUT Vannes

Université Bretagne Sud

1 Introduction et objectif

Symrise est une entreprise internationale spécialisée dans les arômes, parfums et solutions nutritionnelles, avec une forte expertise dans l'alimentation animale. Grâce à son approche innovante, Symrise développe des produits qui allient l'attractivité sensorielle et bénéfices nutritionnels pour répondre aux besoins des animaux et des propriétaires.

Dans ce cadre, l'étude menée vise à comprendre les préférences alimentaires des chiens face à différentes compositions développées par Symrise. Pour ce faire, un échantillon de 109 chiens a été sélectionné, et plus de 900 tests ont été réalisés. Au cours de ces tests, chaque chien devait choisir entre deux aliments proposés simultanément. Pour connaître quels types d'aliments sont préférés de la part des chiens, nous allons faire différents tests qui vont nous permettre de mieux comprendre les envies des chiens.

Les 8 compositions alimentaires testées sont définies comme ci-dessous :

- | | |
|-----------------|----------------|
| - 4% SL | - 2% PL |
| - 2% PL + 1% P | - 4% PL |
| - 4% PL + 1% PL | - 2% SL |
| - 4% SL + 1% P | - 2% SL + 1% P |

Le jeu de données est organisé de manière à détailler chaque test. Chaque ligne correspond à une observation unique où un chien a dû choisir entre deux aliments, identifiés comme *Aliment A* et *Aliment B*. Les informations suivantes sont enregistrées :


- **Date du test**
- **Libellé des aliments** (A et B, incluant leurs compositions respectives)
- **Nom de l'animal**
- **Caractéristiques du chien** : poids, genre et âge
- **Quantité consommée** : pour chaque aliment (A et B)
- **Ratios de consommation** : par exemple, si un chien consomme 90 grammes de l'aliment A et 10 grammes de l'aliment B, la colonne *Ratio A* indiquera 90, et *Ratio B*, 10.

Cette étude vise à explorer les préférences alimentaires des chiens en fonction de ces compositions, tout en tenant compte de leurs caractéristiques individuelles. Pour cela nous utiliserons différentes méthodes statistiques comme la comparaison par paire afin d'évaluer quel mélange et le préférer des chiens.

2 Data visualisation et analyse descriptive

Dans un premier temps, nous avons mis en place des statistiques descriptives afin de mieux comprendre les données sur lesquelles nous allons travailler.

Nous avons donc ci-dessous des histogrammes sur les différentes variables quantitatives et qualitatives de notre jeu de données.



La population de l'étude présente un équilibre parfait entre les sexes et une répartition homogène des gabarits, bien que les chiens de petite taille et de moins de deux ans soient les plus représentés. Les poids observés s'étendent de 0 à 50 kg avec une forte concentration sous le seuil des 10 kg, ce qui est cohérent avec la structure démographique des sujets testés.

L'analyse des consommations révèle un comportement bimodal très marqué, où les animaux choisissent quasi exclusivement l'un des deux produits plutôt que de partager leur consommation. Cette discrimination nette, couplée à une distribution symétrique des huit aliments dans le plan d'expérience, assure une base de données robuste pour l'estimation des scores de préférence.

3 Modèle statistique

À la suite de ces statistiques, nous avons mis en place des analyses qui nous permettront de tirer des conclusions sur les différents produits utilisés lors des différents tests de produit sur l'alimentation des chiens. Notre analyse sur les préférences alimentaires chez le chien repose sur l'utilisation du modèle de Bradley-Terry, une approche probabiliste de référence pour le traitement des données issues de comparaisons par paires.

3.1 Fondement Mathématique du Modèle

Le modèle postule que chaque aliment i possède une "capacité" ou un score d'attractivité intrinsèque noté π_i . La probabilité P_{ij} que l'aliment i soit préféré à l'aliment j est défini par le rapport :

$$P_{ij} = \frac{\pi_i}{\pi_i + \pi_j}$$

Grâce au package `BradleyTerry2`, ces scores sont estimés via une transformation logistique (logit) puis normalisés (leur somme égale 1). Cela permet d'obtenir un classement hiérarchique où chaque score représente la "part de préférence" du produit.


La fiabilité des résultats repose sur plusieurs tests de validation statistique :

- **Significativité globale** : Un test du rapport de vraisemblance (Likelihood Ratio Test) a été réalisé pour confirmer que les différences de consommation entre les produits sont statistiquement significatives ().
- **Qualité de l'ajustement (Goodness-of-Fit)** : La déviance résiduelle du modèle a été analysée. Une p-value supérieure à 0,05 indique que le modèle de Bradley-Terry est mathématiquement adapté pour décrire la structure de nos données.
- **Cohérence et Transitivité** : À l'aide de la fonction `strans` du package `eba`, nous avons vérifié la transitivité des choix. Cette étape assure l'absence de paradoxes de préférence (type "A bat B, B bat C, mais C bat A"), garantissant la robustesse du classement final.

Cette approche nous a fourni des résultats détaillés que nous allons maintenant analyser pour valider nos hypothèses et segmenter les comportements observés.

4 Interprétation des résultats

Dans un premier temps, nous avons mis en place un graphique en ballon. Ce graphique nous permet de connaître les préférences des produits par rapport à chacun des autres produits qui sont testés.




Sur ce graphique, nous pouvons donc constater que les produits avec 4 % de PL + 1 % de P sont les préférés. Plus généralement, on peut même remarquer que ce sont les produits avec 4 % PL et 4 % SL + P qui sont appréciés. Cela nous permet de voir une sorte de hiérarchisation des produits entre ceux qui sont plus riches et ceux qui le sont moins. On peut admettre que lorsqu'on diminue les pourcentages de protéine alors les chiens sont moins attirés par l'aliment en question. On peut donc déjà en conclure que le fait d'avoir des produits plus riches attirent davantage les chiens donc il est nécessaire de se concentrer sur ces produits et de les mettre en avant.

```
##
## Call:
## BTm(outcome = cbind(CONSO_A, CONSO_B), player1 = alimentA, player2 = alimentB,
## id = "aliment", data = somme)
##
## Coefficients:
##      Estimate Std. Error z value Pr(>|z|)
## aliment2% PL + 1% P  1.34844    0.01633   82.58 <2e-16 ***
## aliment2% SL+ 1% P   0.60308    0.01467   41.11 <2e-16 ***
## aliment2%SL         -0.76309    0.01864  -40.94 <2e-16 ***
## aliment4% PL        1.61265    0.01549  104.09 <2e-16 ***
## aliment4% PL + 1% P  2.17084    0.01580  137.43 <2e-16 ***
## aliment4% SL        0.88184    0.01518   58.11 <2e-16 ***
## aliment4% SL + 1% P  1.68286    0.01645  102.33 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 55096.0 on 28 degrees of freedom
## Residual deviance: 3357.8 on 21 degrees of freedom
## AIC: 3614.1
##
## Number of Fisher Scoring iterations: 4
```

Cette sortie Rstudio, nous permet de comparer les différents coefficients de chacun de nos produits. Ces coefficients correspondent aux résultats que l'on avait trouvés précédemment, c'est-à-dire que les produits les plus riches sont principalement consommés d'après les coefficients de « Estimate ». On peut voir que la déviance à un score de 55 096 et que son résidu à un score de 3357.8 ce qui est faible

comparé au score. Grâce à ces résultats, on peut voir que ce modèle permet de bien expliquer les préférences des aliments.

Suite à cela, nous avons décidé de mettre en place un score de Bradley, ce score va nous permettre de mieux distinguer les préférences des chiens et donc de voir quels sont les produits qui attirent le plus les chiens.




Sur ce score de Bradley, nous pouvons voir que le produit A, constitué de 4% de PL et 1% de P, est largement supérieur aux autres avec un score de 0.3 tandis que tous les autres scores sont en dessous de 0.2 voire 0.05 pour les produits G et H. Ce résultat nous permet de mieux comprendre le balloonplot que l'on fait et de mieux interpréter nos résultats. Le score de Bradley vient appuyer le fait que l'utilisation des produits les plus riches sont plus demandés par les chiens.


```
## Call:
## BIm(outcome = cbind(CONSO_A, CONSO_B), player1 = alimentA, player2 = alimentB,
## formula = ~aliment + biais.posit, id = "aliment", data = somme)
##
## Coefficients:
##      Estimate Std. Error z value Pr(>|z|)
## aliment2% PL + 1% P  1.343634  0.016183  83.03 <2e-16 ***
## aliment2% SL + 1% P  0.562232  0.014823  37.93 <2e-16 ***
## aliment2%SL        -0.795426  0.018696 -42.55 <2e-16 ***
## aliment4% PL       1.580150  0.015614 101.20 <2e-16 ***
## aliment4% PL + 1% P  2.160018  0.015915 135.72 <2e-16 ***
## aliment4% SL       0.829788  0.015165  54.72 <2e-16 ***
## aliment4% SL + 1% P  1.628881  0.016424  99.18 <2e-16 ***
## biais.posit        -0.141047  0.006017 -23.44 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
## Null deviance: 55096.0 on 28 degrees of freedom
## Residual deviance: 2807.9 on 20 degrees of freedom
## AIC: 3066.2
##
## Number of Fisher Scoring iterations: 4
```

Cette sortie, va nous permettre de voir si on a pu améliorer notre modèle, pour cela, on peut déjà voir que les coefficients estimés sont quasiment les mêmes et sont toujours pour les mêmes types d'aliment. On peut également observer que la déviance n'a pas changé, elle est toujours de 55 096 mais le résidu quant à lui a diminué ce qui nous permet de conclure que l'on a réussi à améliorer notre modèle afin d'avoir de meilleurs


résultats. De plus, si on regarde l'AIC on peut voir que sur le premier modèle, le score était de 3614.1 et maintenant il a diminué à 3066.2. La diminution de l'AIC montre que le modèle s'améliore et que nos résultats sont plus précis, cela permet de montrer qu'il y a un meilleur compromis entre l'ajustement et la complexité du modèle.



Pour finir, nous avons créé un score de Bradley permettant de comparer les scores afin de savoir s'il y avait un biais ou non. On peut voir que le fait d'avoir un biais ou pas ne change pas nos résultats. Les écarts entre chaque produit est presque le même, les courbes sont principalement horizontales et les changements sont minimales. On sait donc que peu importe la position du produit, ce sont toujours les mêmes qui sont mis en avant.



Pour essayer d'améliorer de nouveau notre modèle, nous avons voulu mettre en place des clusters. Pour cela, nous avons fait un critère de BIC qui va nous permettre de connaître le nombre de classe à utiliser. Pour donner suite aux résultats du graphique ci-dessus, on peut voir qu'il est préférable d'avoir 2 clusters. Par la suite, nous avons donc fait un score de Bradley afin de savoir si cela pourrait améliorer notre modèle de base.



Ce score de Bradley nous permet de voir que les 2 clusters que nous avons créés sont différents sur certains points comme le fait que l'aliment avec 2 % PL + 1 % P est très apprécié même s'il reste toujours en dessous de 4 % PL + 1 % P qui reste toujours l'aliment principal. Cependant, on peut voir tout de même une augmentation du score pour plusieurs produits dans le cluster 2, ce ne sont que des produits qui sont les plus riches avec une augmentation de 4 %. Néanmoins, on voit que les aliments avec 2 % ne sont pas favorisés dans les 2 clusters, cela montre que ces aliments n'intéressent pas les chiens et qu'il faudrait se focaliser sur les produits avec 4 %.

5 Conclusion

Cette étude avait pour objectif d'analyser les préférences alimentaires des chiens face à différentes formulations développées par Symrise, en comparant des compositions à base de Premium Liquide (PL), Standard Liquide (SL) et de Poudre (P). L'analyse s'appuie sur plus de 900 tests de choix réalisés auprès de 109 chiens, traités à l'aide du modèle de Bradley-Terry, particulièrement adapté aux comparaisons par paires.

Les résultats mettent en évidence une tendance très marquée : les aliments contenant une forte proportion de Premium Liquide sont systématiquement les plus appréciés. En particulier, la formulation composée de 4 % de PL + 1 % de P se distingue nettement comme l'aliment le plus attractif, avec un score de préférence largement supérieur aux autres produits. À l'inverse, les compositions reposant majoritairement sur le Standard Liquide ou sur des taux plus faibles (2 %) présentent des scores de préférence faibles, traduisant un intérêt limité de la part des chiens. Ces résultats sont cohérents sur l'ensemble des analyses menées et restent stables malgré les tests de robustesse et la segmentation en clusters.

D'un point de vue applicatif, ces conclusions suggèrent que la qualité et la richesse des formulations, et plus particulièrement l'utilisation du Premium Liquide, jouent un rôle déterminant dans l'attractivité des aliments pour chiens. Pour Symrise, il apparaît pertinent de concentrer les efforts de développement et de valorisation commerciale sur les produits à base de PL, notamment ceux formulés à 4 %, qui constituent un levier fort d'appétence. Les produits à base de SL ou à faible concentration pourraient être repositionnés ou optimisés, par exemple via l'ajout de poudre ou l'amélioration de leur profil aromatique.